RAPPORT ANALYTIQUE

Analyse Multidimensionnelle de l'Impact de la Coupe du Monde FIFA

La Coupe du Monde améliore-t-elle réellement le développement économique, social, environnemental et urbain des pays hôtes ?

Auteure	Formation
Hajar Ait Lachgar	Data Analyst — Simplon
Date	**Période analysée**
Mars 2026	2003 – 2025 | 5 pays hôtes

github.com/hajaraitlachgar/Impact_CDM

1. Résumé Exécutif

Ce rapport présente une analyse multidimensionnelle de l'impact de la Coupe du Monde FIFA sur cinq pays hôtes — Allemagne (2006), Afrique du Sud (2010), Brésil (2014), Russie (2018) et Qatar (2022) — sur la période 2003–2025. Il constitue le livrable analytique principal du projet fil rouge de formation Data Analyst chez Simplon.

Le projet repose sur un pipeline data complet : extraction via l'API World Bank et des rapports FIFA, nettoyage et harmonisation par pays et par fenêtre temporelle de ±3 ans autour de chaque édition, exploration statistique (EDA), et restitution visuelle via un dashboard Power BI interactif.

Points clés du projet

- 8 datasets traités : économique, environnemental, social, urbain, WHR, FIFA, CO2 annuel, CO2 par habitant
- 5 pays hôtes analysés sur des fenêtres temporelles symétriques de 7 ans (3 avant, année CDM, 3 après)
- 16 KPIs calculés couvrant les dimensions économique, sociale, environnementale et urbaine
- Pipeline entièrement reproductible : notebooks Python documentés + CSV nettoyés + dashboard Power BI
- Approche temporelle avant / pendant / après pour isoler l'effet Coupe du Monde

2. Contexte et Problématique

2.1 Contexte métier

La Coupe du Monde de la FIFA est l'événement sportif le plus suivi au monde, rassemblant plus de 3 milliards de téléspectateurs à chaque édition. Au-delà du spectacle sportif, l'organisation de cet événement représente un investissement massif pour les pays hôtes : infrastructures sportives, réseaux de transport, sécurité, tourisme et communication internationale.

Ces investissements sont justifiés par la promesse d'un héritage positif à long terme — relance économique, amélioration du bien-être social, modernisation des villes. Pourtant, plusieurs études académiques ont mis en évidence des résultats contrastés, voire des effets négatifs pour certains pays (endettement public, déplacements de populations, dégradation environnementale).

2.2 Problématique centrale

> ▸ La Coupe du Monde améliore-t-elle réellement le développement économique, social, environnemental et urbain des pays hôtes ?

2.3 Objectifs spécifiques

- Évaluer l'impact économique (PIB, IDE, tourisme, emploi) avant et après l'événement
- Mesurer l'évolution du bien-être social via le Life Satisfaction Index (World Happiness Report)
- Analyser les effets environnementaux (émissions CO2, énergie renouvelable)
- Étudier l'héritage urbain et infrastructurel (urbanisation, connectivité Internet)
- Comparer les 5 pays hôtes entre eux pour identifier des profils d'impact distincts

2.4 Périmètre de l'étude

Pays hôtes analysés	Allemagne (2006), Afrique du Sud (2010), Brésil (2014), Russie (2018), Qatar (2022)
Période globale	2003 – 2025
Fenêtre par pays	7 ans : 3 ans avant CDM, année CDM, 3 ans après
Granularité	Annuelle
Sources de données	World Bank API, World Happiness Report, FIFA, Our World in Data

3. Sources de Données

Le projet mobilise 4 types de sources de données différentes, couvrant les dimensions économique, sociale, environnementale et urbaine. L'ensemble des fichiers sources est versionné sur le dépôt GitHub.

Source	Type	Fichier CSV nettoye	Indicateurs
World Bank API	API REST	economic / environmental / social / urban CSV	PIB, IDE, inflation, emploi, CO2, énergie, urbanisation, Internet
World Happiness Report	CSV (sep=;)	WHR.csv → cleaned_whrdata.csv	Life Satisfaction (Life Evaluation, moyenne 3 ans)
FIFA (rapports off.)	CSV manuel	worldCupData.csv	Stades, budget, emplois créés, coûts d'infrastructure
Our World in Data	CSV open	annual-co2 / co2-per-capita CSV	Émissions CO2 totales et par habitant (série longue)

3.1 Justification des sources

- **World Bank Open Data :** Source officielle et internationale, données comparables dans le temps, extraction automatisée via API Python (requests).
- **World Happiness Report :** Seul indicateur standardisé de satisfaction de vie à l'échelle mondiale. Limite reconnue : disponibilité partielle avant 2011 et lissage sur 3 ans.
- **Données FIFA :** Données primaires sur les investissements liés à l'organisation. Collecte manuelle nécessaire (non disponibles via API standardisée).
- **Our World in Data :** Source académique fiable pour les séries longues sur les émissions carbone, complémentaire aux données World Bank.

4. Architecture Data et Pipeline

4.1 Structure du projet

Le projet adopte une architecture data en couches, avec une séparation claire entre les données brutes, les données nettoyées et les livrables analytiques.

Structure du dépôt GitHub

- Data Collection/ — données brutes extraites des sources (CSV, API)
- Data Clean/ — données nettoyées et harmonisées (8 fichiers CSV)
- EDA.ipynb — analyse exploratoire par dataset
- Nettoyage.ipynb — pipeline de nettoyage complet
- Dashboard_Impact_CDM.pbix — dashboard Power BI interactif
- README.md — documentation du projet

4.2 Pipeline de traitement

Etape 1 — Extraction

Les données économiques, sociales, environnementales et urbaines sont extraites via l'API REST de la World Bank (bibliothèque requests Python). Les données FIFA sont collectées manuellement depuis les rapports officiels. Les séries CO2 proviennent de Our World in Data.

Etape 2 — Exploration (EDA)

Le notebook EDA.ipynb réalise une analyse exploratoire structurée par dataset : statistiques descriptives (describe()), analyse des valeurs nulles et des doublons, distributions par pays et par année. Les 8 datasets sont explorés de façon systématique.

Etape 3 — Nettoyage et Harmonisation

Le notebook Nettoyage.ipynb met en oeuvre un pipeline de nettoyage rigoureux, articulé autour de deux opérations clés :

- Filtrage temporel par pays : extraction de la fenêtre de 7 ans pertinente pour chaque pays hôte
- Harmonisation des identifiants pays : conversion des codes ISO 3 lettres (DEU, ZAF, BRA, RUS, QAT) vers les noms complets
- Concénération des 5 pays dans un dataset unique par dimension
- Export en CSV nettoyés dans le dossier Data Clean/

Fenêtres temporelles appliquées

Allemagne (DEU)	CDM 2006 → 2003 – 2009
Afrique du Sud (ZAF)	CDM 2010 → 2007 – 2013
Brésil (BRA)	CDM 2014 → 2011 – 2017
Russie (RUS)	CDM 2018 → 2015 – 2021
Qatar (QAT)	CDM 2022 → 2019 – 2025

5. Nettoyage et Qualité des Données

Le nettoyage des données constitue une étape critique pour garantir la fiabilité des analyses. Le pipeline Nettoyage.ipynb traite 8 datasets de façon systématique et documentée.

Dataset	Operations realisees	Resultat
economic_world_cup_data.csv	Filtrage par pays et fenêtre temporelle, mapping ISO → nom, concat 5 pays, vérification nulls/doublons	cleaned_economic_world_cup_data.csv — 0 doublon
environmental_world_cup_data.csv	Même pipeline que le dataset économique	cleaned_envirennement_world_cup_data.csv
social_indicators.csv	Filtrage temporel, mapping ISO, concénération	cleaned_social_world_cup_data.csv
urban_infrastructure_data.csv	Filtrage temporel, mapping ISO, concénération	cleaned_urban_world_cup_data.csv
WHR.csv (sep=;)	Filtrage par nom de pays (déjà en anglais), fenêtres temporelles, concénération	cleaned_whrdata.csv
annual-co2-emissions-per-country.csv	Filtrage par Entity (nom pays), fenêtres temporelles, concénération	cleaned_annual_co2_emissions_per_country.csv
co-emissions-per-capita.csv	Même logique que CO2 annuel	cleaned_co2_emissions_per_capita.csv
worldCupData.csv (FIFA)	Données FIFA structurées manuellement — vérification des indicateurs (stades, budget, emplois)	Utilisé directement dans Power BI

5.1 Observations qualité

- Aucun doublon détecté dans les datasets économique, environnemental, social et urbain après filtrage.
- Valeurs nulles présentes pour le taux de criminalité (données incomplètes pour le Qatar) et les énergies renouvelables (séries courtes).
- Le WHR présente une couverture partielle avant 2011 pour certains pays — limite documentée et prise en compte dans l'interprétation.
- Le mapping ISO → nom pays garantit la cohérence des jointures dans Power BI.

6. Indicateurs Clés de Performance (KPIs)

Les KPIs sont organisés en quatre dimensions analytiques. Ils sont calculés à partir des datasets nettoyés et implémentés dans le modèle Power BI via des mesures DAX.

6.1 KPIs Economiques

KPI	Source	Interpretation metier
GDP Growth Variation	World Bank API	Variation de la croissance du PIB autour de l'année CDM pour quantifier le stimulus économique direct
FDI Growth Rate	World Bank API	Évalue l'attractivité du pays pour les investisseurs étrangers dans la période pré/post CDM
Tourism Growth Rate	World Bank API	Quantifie l'augmentation des arrivées touristiques internationales liée à l'événement
Employment Change	World Bank API	Mesure la variation du taux d'emploi pour évaluer la création d'emplois directe et induite
ROI Economique	FIFA + World Bank	Rapport entre l'impact économique estimé et le budget total investi dans l'organisation

6.2 KPIs Sociaux

KPI	Source	Interpretation metier
Life Satisfaction Index	World Happiness Report	Score de satisfaction de vie (0–10) — proxy du bien-être social perçu par la population
Life Satisfaction Growth	WHR	Variation du score WHR entre la période pré-CDM et post-CDM
Crime Rate Variation	World Bank / Social	Evolution du taux de criminalité — indicateur de sécurité et de cohésion sociale
Quality of Life Index	Multi-sources	Indicateur composite croisant PIB/habitant, santé et satisfaction de vie

6.3 KPIs Environnementaux

KPI	Source	Interpretation metier
CO2 per capita variation	Our World in Data	Variation des émissions CO2 par habitant pour mesurer la pression environnementale
Energy consumption var.	World Bank / Env	Evolution de la consommation d'énergie par habitant (kWh)
Renewable energy share	World Bank / Env	Part des énergies renouvelables dans le mix énergétique — indicateur de transition écologique

6.4 KPIs Urbains / Infrastructures

KPI	Source	Interpretation metier
Infrastructure invest. ratio	World Bank / FIFA	Part du PIB consacrée aux investissements en infrastructures
Internet penetration growth	World Bank / Urb	Progression du taux d'accès à Internet — indicateur de modernisation numérique
Infrastructure legacy score	FIFA + World Bank	Score composite évaluant l'héritage infrastructurel laissé après la CDM

7. Analyse Exploratoire des Données (EDA)

L'analyse exploratoire a été conduite dataset par dataset dans le notebook EDA.ipynb. Elle constitue l'étape de compréhension des données brutes avant toute transformation, permettant d'identifier les anomalies, les distributions et les patterns initiaux.

7.1 Méthodologie EDA

- head() — Inspection des premières lignes pour valider la structure et les types de colonnes
- shape — Vérification des dimensions (lignes x colonnes) par dataset
- info() — Identification des types de données et des colonnes à retyper
- describe() — Statistiques descriptives (min, max, moyenne, écart-type, quartiles)
- value_counts('Country') — Distribution des observations par pays
- isnull().sum() + duplicated().sum() — Audit qualité : valeurs manquantes et doublons

7.2 Résultats EDA par dataset

Dataset Economique (dfEco)

Indicateurs : croissance PIB, inflation, IDE, arrivées touristiques, taux d'emploi, population. Distribution cohérente entre pays. Certaines valeurs manquantes sur l'IDE pour des années antérieures.

Dataset Environnemental (dfEnv)

Indicateurs : émissions CO2, consommation d'énergie, part des renouvelables, transport aérien. Valeurs manquantes sur la part des renouvelables pour le Qatar (données récentes incomplètes).

Dataset Social (dfSoc)

Indicateurs : satisfaction de vie, participation à la population active, criminalité, PIB/habitant. Taux de criminalité peu renseigné pour le Qatar — limite documentée.

Dataset Urbain (dfUrb)

Indicateurs : investissements en infrastructures, urbanisation, accès Internet, abonnements mobiles. Données complètes pour la majorité des pays et des années.

World Happiness Report (dfWhr)

Life Evaluation score disponible dès 2005 pour l'Allemagne. Disponibilité partielle pour l'Afrique du Sud avant 2011. Données Qatar disponibles à partir de 2012.

Données FIFA (dfFifa)

Dataset structuré manuellement à partir des rapports officiels FIFA. 5 observations (une par édition). Indicateurs : stades, budget, emplois créés, coûts d'infrastructure, héritage.

CO2 Total et per capita (Our World in Data)

Séries longues et complètes pour les 5 pays. Filtrage appliqué sur les fenêtres temporelles de chaque pays. Aucune valeur manquante après filtrage.

8. Analyse et Résultats

Cette section présente les résultats analytiques obtenus pour chaque dimension, restitués à travers le dashboard Power BI interactif. L'approche adoptée est une comparaison systématique avant / pendant / après pour chaque pays hôte.

8.1 Dimension Economique

L'analyse économique révèle des patterns distincts selon le contexte macroéconomique préexistant du pays hôte. Cinq profils d'impact émergent.

Observations économiques clés

- Allemagne (2006) : contexte économique stable, impact limité mais positif. Croissance PIB maintenue, afflux touristique notable (+20% sur l'année CDM).
- Afrique du Sud (2010) : investissements massifs (~3,9 Mds USD). Impact touristique déçevant par rapport aux projections initiales.
- Brésil (2014) : coûts d'organisation très élevés (~15 Mds USD). Récession économique dans les années suivantes — le cas le plus contrasté.
- Russie (2018) : organisation de grande envergure, suivie d'un contexte géopolitique défavorable limitant les bénéfices économiques durables.
- Qatar (2022) : investissements records (~220 Mds USD). Fort héritage infrastructurel attendu. Données post-CDM partielles.

8.2 Dimension Sociale

L'indicateur Life Satisfaction du World Happiness Report permet de mesurer l'évolution du bien-être perçu par les populations. Cet indicateur capture des effets diffus que les données économiques ne reflètent pas.

Observations sociales clés

- Allemagne : score WHR stable et élevé sur toute la période (autour de 7/10). L'effet CDM est difficile à isoler dans un contexte de bien-être déjà très élevé.
- Afrique du Sud : progression modérée du Life Satisfaction, mais persistance d'inégalités sociales importantes malgré les investissements.
- Brésil : score WHR en baisse sur la période post-CDM, corrélé aux tensions politiques et économiques de 2015–2016.
- Russie : stabilité relative avant 2018, puis baisse liée au contexte géopolitique.
- Qatar : données WHR limitées. Héritage social (droits des travailleurs, réformes) fortement médiatisé.

8.3 Dimension Environnementale

La dimension environnementale constitue l'un des aspects les plus sensibles, notamment depuis l'édition Qatar 2022 et son bilan carbone fortement controversé.

Observations environnementales clés

- Une augmentation des émissions CO2 est observable dans les 1–2 ans précédant chaque CDM, portée par les chantiers de construction massifs.
- L'Allemagne (2006) présente les meilleures performances environnementales relatives, avec une part croissante des énergies renouvelables.
- Le Brésil maintient une part élevée d'énergies renouvelables (hydroélectricité) mais voit sa consommation d'énergie augmenter.
- Le Qatar affiche les émissions CO2 per capita les plus élevées parmi les 5 pays, malgré les engagements officiels de neutralité carbone.

8.4 Dimension Urbaine et Infrastructurelle

L'héritage urbain est souvent présenté comme la justification principale des investissements liés à la CDM. C'est effectivement la dimension la plus mesurable et la plus durable.

Observations urbaines clés

- Tous les pays hôtes enregistrent une accélération de l'accès à Internet dans les années entourant la CDM.
- Le taux d'urbanisation progresse de façon continue, avec une accélération observable pour le Brésil et l'Afrique du Sud.
- Les infrastructures de transport (aéroports, routes, transports en commun) constituent l'héritage le plus durable selon les données FIFA.
- Le Qatar présente l'Infrastructure Legacy Score le plus élevé, porté par des investissements sans précédent.

9. Dashboard Power BI

9.1 Architecture du modèle de données

Le dashboard Power BI s'appuie sur un modèle en étoile (Star Schema) connectant les 8 CSV nettoyés, reliés via les clés Country et Year.

Structure du modèle Star Schema

- Table de faits : données économiques, sociales, environnementales et urbaines consolidées
- Dimension pays : 5 pays hôtes avec métadonnées (région, date CDM)
- Dimension temps : années 2003–2025, avec balisage avant / pendant / après CDM
- Dimension CDM (FIFA) : budget, stades, emplois, coûts par édition
- Mesures DAX : calcul des 16 KPIs, variations avant/après, scores composites

9.2 Pages et visualisations

- **Page 1 — Vue d'ensemble :** KPIs globaux par pays, timeline des éditions CDM, filtres interactifs par pays et dimension.
- **Page 2 — Impact Economique :** Evolution PIB, IDE, tourisme et emploi en courbes avant/après CDM par pays.
- **Page 3 — Impact Social :** Life Satisfaction Index et évolution WHR, Quality of Life Index.
- **Page 4 — Impact Environnemental :** CO2 per capita, part des énergies renouvelables, consommation énergétique.
- **Page 5 — Héritage Urbain :** Pénétration Internet, urbanisation, Infrastructure Legacy Score.
- **Page 6 — Comparaison pays :** Tableau comparatif multi-KPIs, radar chart des 5 pays hôtes.

Etat d'avancement du dashboard

- Le modèle de données Star Schema est connecté aux 8 datasets nettoyés.
- Les mesures DAX pour les KPIs économiques et sociaux sont implémentées.
- Les pages de visualisation sont structurées. La mise en forme et les interactions finales sont en cours de finalisation.

10. Outils et Technologies

Python (Pandas, NumPy, Requests)	Extraction API, nettoyage, EDA, calcul des KPIs
Jupyter Notebooks	EDA.ipynb, Nettoyage.ipynb — pipeline documenté et reproductible
Power BI Desktop	Modélisation Star Schema, mesures DAX, dashboard interactif
GitHub	Versioning du code, organisation du dépôt, documentation README
Trello	Gestion de projet : tâches, jalons, avancement
Confluence / Atlassian	Documentation technique du projet
API World Bank	Extraction automatisée des indicateurs macroéconomiques

11. Limites et Perspectives

11.1 Limites identifiées

- Disponibilité du WHR : couverture partielle avant 2011, lissage sur 3 ans limitant la précision à court terme.
- Données Qatar post-CDM incomplètes : l'édition 2022 est trop récente pour mesurer l'impact à long terme.
- Causalité vs. corrélation : les variations observées peuvent être influencées par des facteurs exogènes (crises, pandémie, géopolitique).
- Données FIFA manuelles : la collecte manuelle introduit un risque d'erreur et limite la reproductibilité automatisée.

11.2 Perspectives d'amélioration

- Analyse de causalité par régression différences-en-différences (DiD) pour mieux isoler l'effet CDM des tendances de fond.
- Intégration de données sentiment (réseaux sociaux) pour enrichir la dimension sociale.
- Extension à d'autres méga-événements sportifs (Jeux Olympiques) pour valider les conclusions par comparaison.
- Automatisation de l'extraction des données FIFA via web scraping éthique.
- Mise en production du dashboard sur Power BI Service pour des mises à jour automatisées.

12. Conclusion

Ce projet démontre que l'impact de la Coupe du Monde sur les pays hôtes est multidimensionnel, nuancé et fortement dépendant du contexte préexistant. Il n'existe pas de réponse universelle : certains pays ont tiré des bénéfices durables de l'organisation (héritage urbain, attractivité internationale), tandis que d'autres ont subi des coûts économiques et sociaux significatifs.

D'un point de vue technique, ce projet met en oeuvre l'ensemble du cycle de vie de la donnée : extraction automatisée, nettoyage rigoureux, exploration analytique, modélisation et restitution visuelle. Il constitue une démonstration concrète des compétences du référentiel Data Analyst.

Enseignements principaux

- L'héritage urbain et infrastructurel est l'impact le plus mesurable et le plus durable de la CDM.
- L'impact économique à court terme est réel mais ne garantit pas une dynamique durable.
- Le bien-être social (Life Satisfaction) est influencé par des facteurs bien plus larges que la seule organisation d'un événement sportif.
- L'impact environnemental est systématiquement négatif à court terme.
- La qualité et la disponibilité des données constituent le principal déterminant de la robustesse des analyses.

Livrables produits

- Notebooks Python documentés : EDA.ipynb, Nettoyage.ipynb
- 8 fichiers CSV nettoyés et harmonisés dans Data Clean/
- Dashboard Power BI interactif (en cours de finalisation)
- Rapport analytique structuré en data storytelling (présent document)
- Dépôt GitHub organisé avec README complet
- Outil de suivi de projet Trello + documentation Confluence

github.com/hajaraitlachgar/Impact_CDM | Mars 2026